UNIVERSIDAD NACIONAL DE INGENIERÍA

Facultad de Ingeniería Eléctrica y Electrónica



INTELIGENCIA ARTIFICIAL II

Profesor

Yury Oscar Tello Canchapoma

Estudiante:

Berrocal Barrientos Jorge Luis

Sección: M

2026

Diagnóstico

LÍNEA DE INVESTIGACIÓN: Inteligencia artificial explicable (XAI) aplicada a la ciberseguridad

Los Centros de Operaciones de Seguridad (SOC) que monitorean redes IoT deben revisar a diario un gran volumen de alertas generadas por sistemas de detección de intrusiones (IDS), cada vez más basados en modelos de aprendizaje automático. Aunque estos modelos alcanzan una alta exactitud, operan como «cajas negras»: entregan una etiqueta o una puntuación de riesgo sin indicar qué características del tráfico motivaron la decisión. Esta opacidad obliga a los analistas a reconstruir manualmente la evidencia de cada alerta, dificulta descartar los falsos positivos, alimenta la fatiga por alertas y reduce la confianza en la detección automatizada. Una encuesta global reportó que los equipos SOC reciben en promedio 4 484 alertas diarias y que el 67 % queda sin atender (Vectra AI, 2023), y estudios académicos confirman que la validación manual de falsos positivos conduce al agotamiento y la desensibilización de los analistas (Alahmadi et al., 2022). El problema se agrava en las redes IoT, formadas por dispositivos heterogéneos y con pocos recursos que son blanco frecuente de botnets como Mirai. En el Perú, la escasez de profesionales especializados en ciberseguridad hace aún más necesario que cada alerta llegue acompañada de una justificación comprensible. Se investigará si un marco de explicabilidad que integra SHAP y LIME a un detector de intrusiones basado en Random Forest mejora la interpretabilidad de las alertas, medida por la fidelidad, la estabilidad y la parsimonia de sus explicaciones, sin deteriorar el desempeño de detección. Para ello se empleará el tráfico de red del dataset CIC-YNU-IoTMal (2026), elaborado por el Canadian Institute for Cybersecurity y la Yokohama National University a partir de muestras de malware IoT capturadas a nivel mundial por los honeypots IoTPOT y disponible en Kaggle.

Tema General:

SOC que monitorean redes IoT a nivel internacional, 2026

Temas Particulares:

1. Detección de intrusiones en SOC que monitorean redes IoT a nivel internacional, 2026.
2. Alertas de detección de intrusiones en SOC que monitorean redes IoT a nivel internacional, 2026.
3. Respuesta a incidentes de seguridad en SOC que monitorean redes IoT a nivel internacional, 2026.

Temas Específicos:

1. Elevada tasa de falsos positivos en las alertas de detección de intrusiones en SOC que monitorean redes IoT a nivel internacional, 2026.
2. Baja interpretabilidad de las alertas de detección de intrusiones en SOC que monitorean redes IoT a nivel internacional, 2026.
3. Sobrecarga de los analistas por el volumen de alertas de detección de intrusiones en SOC que monitorean redes IoT a nivel internacional, 2026.

Problema de estudio:

Baja interpretabilidad de las alertas de detección de intrusiones en SOC que monitorean redes IoT a nivel internacional, 2026.

Título Preliminar de la Tesis:

Interpretabilidad de las alertas de detección de intrusiones en SOC que monitorean redes IoT a nivel internacional, 2026.

Variable Dependiente: Interpretabilidad

Objeto De Estudio: Alertas de detección de intrusiones

Alcance Espacial: SOC que monitorean redes IoT a nivel internacional

Alcance Temporal: 2026

Antecedentes Bibliográficos

1. Wang, M., Zheng, K., Yang, Y., & Wang, X. (2020). An explainable machine learning framework for intrusion detection systems. *IEEE Access*, *8*, 73127–73141. https://doi.org/10.1109/ACCESS.2020.2988359

2. Le, T.-T.-H., Kim, H., Kang, H., & Kim, H. (2022). Classification and explanation for intrusion detection system based on ensemble trees and SHAP method. *Sensors*, *22*(3), 1154. https://doi.org/10.3390/s22031154

3. Alani, M. M., & Miri, A. (2022). Towards an explainable universal feature set for IoT intrusion detection. *Sensors*, *22*(15), 5690. https://doi.org/10.3390/s22155690

4. Younisse, R., Ahmad, A., & Abu Al-Haija, Q. (2022). Explaining intrusion detection-based convolutional neural networks using Shapley additive explanations (SHAP). *Big Data and Cognitive Computing*, *6*(4), 126. https://doi.org/10.3390/bdcc6040126

5. Patil, S., Varadarajan, V., Mazhar, S. M., Sahibzada, A., Ahmed, N., Sinha, O., Kumar, S., Shaw, K., & Kotecha, K. (2022). Explainable artificial intelligence for intrusion detection system. *Electronics*, *11*(19), 3079. https://doi.org/10.3390/electronics11193079

6. Lee, Y., Lee, E., & Lee, T. (2022). Human-centered efficient explanation on intrusion detection prediction. *Electronics, 11*(13), 2082. https://doi.org/10.3390/electronics11132082

7. Larriva-Novo, X., Sánchez-Zas, C., Villagrá, V. A., Marín-Lopez, A., & Berrocal, J. (2023). Leveraging explainable artificial intelligence in real-time cyberattack identification: Intrusion detection system approach. *Applied Sciences, 13*(15), 8587. https://doi.org/10.3390/app13158587

8. Almuqren, L., Maashi, M. S., Alamgeer, M., Mohsen, H., Hamza, M. A., & Abdelmageed, A. A. (2023). Explainable artificial intelligence enabled intrusion detection technique for secure cyber-physical systems. *Applied Sciences, 13*(5), 3081. https://doi.org/10.3390/app13053081

9. Gaspar, D., Silva, P., & Silva, C. (2024). Explainable AI for intrusion detection systems: LIME and SHAP applicability on multi-layer perceptron. *IEEE Access, 12*, 30164–30175. https://doi.org/10.1109/ACCESS.2024.3368377

10. Arreche, O., Guntur, T. R., Roberts, J. W., & Abdallah, M. (2024). E-XAI: Evaluating black-box explainable AI frameworks for network intrusion detection. *IEEE Access, 12*, 23954–23988. https://doi.org/10.1109/ACCESS.2024.3365140

11. Arreche, O., Guntur, T., & Abdallah, M. (2024). XAI-IDS: Toward proposing an explainable artificial intelligence framework for enhancing network intrusion detection systems. *Applied Sciences, 14*(10), 4170. https://doi.org/10.3390/app14104170

12. Chen, X., Liu, M., Wang, Z., & Wang, Y. (2024). Explainable deep learning-based feature selection and intrusion detection method on the Internet of Things. *Sensors, 24*(16), 5223. https://doi.org/10.3390/s24165223

13. Larriva-Novo, X., Pérez Miguel, L., Villagra, V. A., Álvarez-Campana, M., Sanchez-Zas, C., & Jover, Ó. (2024). Post-hoc categorization based on explainable AI and reinforcement learning for improved intrusion detection. *Applied Sciences, 14*(24), 11511. https://doi.org/10.3390/app142411511

14. Hermosilla, P., Berríos, S., & Allende-Cid, H. (2025). Explainable AI for forensic analysis: A comparative study of SHAP and LIME in intrusion detection models. *Applied Sciences, 15*(13), 7329. https://doi.org/10.3390/app15137329

15. Alabbadi, A., & Bajaber, F. (2025). An intrusion detection system over the IoT data streams using eXplainable artificial intelligence (XAI). *Sensors, 25*(3), 847. https://doi.org/10.3390/s25030847

16. Alamro, H., Alahmari, S., Nemri, N., Aljebreen, M., Alhashmi, A. A., Alamro, S., Alqazzaz, A., & Al Duhayyim, M. (2025). Enhanced intrusion detection in cybersecurity through dimensionality reduction and explainable artificial intelligence. *Scientific Reports, 15*, 33848. https://doi.org/10.1038/s41598-025-06761-9

17. Munilla, J., & Khammas, R. M. (2026). Evaluation of explainable artificial intelligence in IoT intrusion detection systems under DeepFool adversarial conditions. *Sensors, 26*(10), 2924. https://doi.org/10.3390/s26102924

18. Ahmed, U., Muhammad, S., & Choi, J. (2026). Explainable intrusion and anomaly detection for IoT sensor networks using hybrid feature selection and deep autoencoder learning. *Sensors, 26*(14), 4540. https://doi.org/10.3390/s26144540

19. Alnsour, A., Zarqou, J., & Shalaldeh, A. (2026). Real-time explanation intrusion detection: An XAI-enriched hybrid CNN-LSTM architecture for operational cybersecurity. *Mathematics, 14*(11), 1977. https://doi.org/10.3390/math14111977

20. Alhalangy, A., Alkhamis, S. A., & Abouelkheir, E. (2026). A stability-centric framework for lightweight and explainable intrusion detection. *Future Internet, 18*(6), 305. https://doi.org/10.3390/fi18060305

Título Tentativo de la Tesis:

Marco de explicabilidad basado en SHAP y LIME para mejorar la interpretabilidad de las alertas de detección de intrusiones en SOC que monitorean redes IoT a nivel internacional, 2026.

Variable Independiente: Marco de explicabilidad basado en SHAP y LIME

Variable Dependiente: Interpretabilidad

Objeto De Estudio: Alertas de detección de intrusiones

Alcance Espacial: SOC que monitorean redes IoT a nivel internacional

Alcance Temporal: 2026

Dataset (Kaggle, publicado por los autores):
https://www.kaggle.com/datasets/raneemababneh/iot-malware-network-traffic-dataset-cic-ynu-2026

Página oficial del dataset (CIC, University of New Brunswick):
https://www.unb.ca/cic/datasets/ynu-iot-2026.html

Referencia del dataset: Dadkhah, S., Okey, O. D., Maret, S. A., Lo, Y.-W., Firouzi, A., Kuki, R., Sasaki, T., Yoshioka, K., Ban, T., Ozawa, S., & Ghorbani, A. A. (2026). CIC-YNU-IoTMal: A comprehensive multilayer dataset for static and dynamic analysis of IoT

malware behavior. *Information Systems*, *140*, 102722.
https://doi.org/10.1016/j.is.2026.102722

MATRIZ DE OPERACIONALIZACIÓN DE VARIABLES

VARIABLE	DEFINICIÓN CONCEPTUAL	DEFINICIÓN OPERACIONAL	DIMENSIONES	INDICADORES	ÍNDICES	ESCALA DE MEDICIÓN
VARIABLE DEPENDIENTE (VD): Interpretabilidad	Grado en que un ser humano puede comprender la causa de una decisión tomada por un modelo (Miller, 2019). En un SOC, la interpretabilidad de las alertas es la capacidad de cada alerta emitida por un detector de intrusiones basado en aprendizaje automático de ir acompañada de una explicación fiel, estable y concisa de las características del tráfico que la motivaron, de modo que el analista pueda validarla o descartarla (Barredo Arrieta et al., 2020; Hermosilla et al., 2025).	**1. Fidelidad de la explicación** Grado en que las características señaladas como más relevantes determinan realmente la predicción del detector; se mide neutralizando las k características principales y observando el cambio en la salida del modelo (Arreche et al., 2024; Hermosilla et al., 2025). **2. Estabilidad de la explicación** Consistencia del conjunto de las k características principales entre ejecuciones repetidas y ante perturbaciones mínimas de la entrada que no alteran la predicción (Hermosilla et al., 2025; Munilla & Khammas, 2026). **3. Parsimonia de la explicación** Concisión de la explicación: número de características necesarias para concentrar la mayor parte de la atribución y facilitar la lectura del analista (Arreche et al., 2024; Munilla & Khammas, 2026).	**1. Fidelidad de la explicación**	**Caída media de probabilidad al neutralizar las k características principales (Δp@k)** $\Delta p@k = (1/N)\ \Sigma\ [p(x_i) - p(x_i \text{ sin top-}k)]$ **Tasa de inversión de la decisión (TID@k, %)** *TID@k = (Alertas cuya clase predicha cambia / Total de alertas) × 100*	**Δp@k:** • Bajo (Deficiente): < 0,20 (la explicación no sostiene la alerta). • Medio (Aceptable): 0,20 – 0,50. • Alto (Óptimo): > 0,50 (las características señaladas explican la alerta). **TID@k:** • Bajo: < 30 %. • Medio: 30 % – 70 %. • Alto (Óptimo): > 70 %.	Razón
			2. Estabilidad de la explicación	**Estabilidad entre ejecuciones (EE, Jaccard top-k)** $EE = (1/N)\ \Sigma\ \bar{J}(T_i^{(r)}, T_i^{(s)});\ J(A, B) = \lvert A \cap B \rvert / \lvert A \cup B \rvert$ **Robustez ante perturbación (RP, Jaccard top-k)** $RP = (1/N)\ \Sigma\ J(T(x_i), T(x_i + \varepsilon))$	**EE:** • Bajo (Inestable): < 0,60. • Medio: 0,60 – 0,80. • Alto (Estable): > 0,80. **RP:** • Bajo (Frágil): < 0,60. • Medio: 0,60 – 0,80. • Alto (Robusta): > 0,80.	
			3. Parsimonia de la explicación	**Número de características para el 80 % de la atribución (NC80)** $NC80 = \text{mín. } m \text{ tal que } \Sigma_{j=1}^{m} \lvert\varphi_{(j)}\rvert / \Sigma \lvert\varphi_j\rvert \geq 0{,}80$ **Concentración de la atribución en el top-3 (CT3, %)** $CT3 = (\Sigma_{j=1}^{3} \lvert\varphi_{(j)}\rvert / \Sigma \lvert\varphi_j\rvert) \times 100$	**NC80:** • Bajo (Difusa): > 7 características. • Medio: 4 – 7 características. • Alto (Concisa): ≤ 3 características. **CT3:** • Bajo: < 50 %. • Medio: 50 % – 80 %. • Alto (Óptimo): > 80 %.	

MATRIZ DE CONSISTENCIA

Título: Marco de explicabilidad basado en SHAP y LIME para mejorar la interpretabilidad de las alertas de detección de intrusiones en SOC que monitorean redes IoT a nivel internacional, 2026.

LÍNEA DE INVESTIGACIÓN	PROBLEMA DE ESTUDIO	PROBLEMAS	HIPÓTESIS	OBJETIVOS	VARIABLES Y DIMENSIONES	DISEÑO METODOLÓGICO
Inteligencia artificial explicable (XAI) aplicada a la ciberseguridad	**Baja** interpretabilidad de las alertas de detección de intrusiones en SOC que monitorean redes IoT a nivel internacional, 2026.	**Problema general:** ¿Cómo mejora el marco de explicabilidad basado en SHAP y LIME la interpretabilidad de las alertas de detección de intrusiones en SOC que monitorean redes IoT a nivel internacional, 2026?	**Hipótesis general:** El marco de explicabilidad basado en SHAP y LIME mejora significativamente la interpretabilidad de las alertas de detección de intrusiones en SOC que monitorean redes IoT a nivel internacional, 2026.	**Objetivo general:** **Desarrollar** un marco de explicabilidad basado en SHAP y LIME que mejore la interpretabilidad de las alertas de detección de intrusiones en SOC que monitorean redes IoT a nivel internacional, 2026.	**Variable independiente:** Marco de explicabilidad basado en SHAP y LIME (Cuantitativo) **Dimensiones** - Desempeño del detector - Eficiencia computacional de la explicación - Concordancia entre métodos explicativos	**Enfoque:** Cuantitativo **Tipo de investigación:** Aplicada **Nivel de investigación:** Correlacional causal (explicativo) **Diseño:** Cuasi-experimental, transversal, de medidas repetidas (pre-test: importancia global del Random Forest; post-test: explicaciones SHAP y LIME de las mismas alertas)
OBJETO DE ESTUDIO Alertas de detección de intrusiones		**Problemas específicos:** 1. ¿En qué medida el marco de explicabilidad basado en SHAP y LIME mejora la *fidelidad de la explicación* de las alertas de detección de intrusiones en SOC que monitorean redes IoT a nivel internacional, 2026? 2. ¿En qué medida el marco de explicabilidad basado en SHAP y LIME asegura la *estabilidad de la explicación* de las alertas de detección de intrusiones en SOC que monitorean redes IoT a nivel internacional, 2026? 3. ¿En qué medida el marco de explicabilidad basado en SHAP	**Hipótesis específicas:** **H.E.1:** El marco de explicabilidad basado en SHAP y LIME mejora significativamente la fidelidad de la explicación de las alertas de detección de intrusiones en SOC que monitorean redes IoT a nivel internacional, 2026. **H.E.2:** El marco de explicabilidad basado en SHAP y LIME asegura una estabilidad de la explicación alta (índice de Jaccard ≥ 0,80) de las alertas de detección de intrusiones en SOC que monitorean redes IoT a nivel internacional, 2026. **H.E.3:** El marco de explicabilidad basado en SHAP y	**Objetivos específicos:** **O.E.1: Analizar** en qué medida el marco de explicabilidad basado en SHAP y LIME mejora la fidelidad de la explicación de las alertas de detección de intrusiones en SOC que monitorean redes IoT a nivel internacional, 2026. **O.E.2: Evaluar** en qué medida el marco de explicabilidad basado en SHAP y LIME asegura la estabilidad de la explicación de las alertas de detección de intrusiones en SOC que monitorean redes IoT a nivel internacional, 2026. **O.E.3: Determinar** en	**Variable dependiente:** Interpretabilidad (Cuantitativo) **Dimensiones** - Fidelidad de la explicación - Estabilidad de la explicación - Parsimonia de la explicación	**Población:** 737 651 ventanas de tráfico de red (PCAP procesado, 39 características) de la partición ARM del dataset CIC-YNU-IoTMal 2026 (CIC-UNB, Canadá; Yokohama National University, Japón) redistribuida en Kaggle, obtenidas al ejecutar en sandbox 5 599 binarios de malware IoT capturados a nivel mundial por honeypots IoTPOT (el dataset completo suma 3 167 325 ventanas en cuatro arquitecturas). Población accesible: 562 378 ventanas de las familias Mirai, DarkNexus y Gafgyt (2 891 binarios); tras la limpieza y el tope de Mirai quedan 175 136 ventanas (130 954 de entrenamiento y 44 182 de prueba). Se excluyen las ejecuciones benignas, generadas con apoyo de modelos de lenguaje, las

		y LIME mejora la *parsimonia de la explicación* de las alertas de detección de intrusiones en SOC que monitorean redes IoT a nivel internacional, 2026?	LIME mejora significativamente la parsimonia de la explicación de las alertas de detección de intrusiones en SOC que monitorean redes IoT a nivel internacional, 2026.	qué medida el marco de explicabilidad basado en SHAP y LIME mejora la parsimonia de la explicación de las alertas de detección de intrusiones en SOC que monitorean redes IoT a nivel internacional, 2026.		etiquetas Unknown y Generic, y las familias con menos de cinco binarios (Tsunami y Agent). **Muestra:** Muestreo probabilístico estratificado por familia sobre las alertas del conjunto de prueba (partición agrupada por binario, 30 %): n = 390 alertas, 130 por familia (Mirai, DarkNexus y Gafgyt); n ≥ 384 (95 % de confianza; e = 5 %). **Técnicas y Herramientas de Recolección de Datos:** **Técnicas:** Observación estructurada; experimentación computacional **Herramientas:** - Registro de observación estructurada (ficha automatizada) - Programa Python (pandas, pyarrow, scikit-learn, shap, lime) **Técnicas de Análisis y Procesamiento de Datos:** **Análisis:** Estadística descriptiva e inferencial: prueba de Friedman, Wilcoxon con corrección de Holm y tamaño del efecto r (α = 0,05) **Procesamiento:** Python (pandas, SciPy), Excel

REGISTRO DE OBSERVACIÓN ESTRUCTURADA

FICHA TÉCNICA DEL INSTRUMENTO DE INVESTIGACIÓN

Variable evaluada	Variable dependiente: Interpretabilidad de las alertas de detección de intrusiones (cuantitativa, escala de razón). Los indicadores de la variable independiente (marco de explicabilidad basado en SHAP y LIME) se registran como condiciones del experimento.
Objetivo del instrumento	Medir y comparar cuantitativamente la interpretabilidad de cada alerta antes (pre-test: importancia global del Random Forest) y después (post-test: explicaciones locales SHAP y LIME) de aplicar el marco de explicabilidad.
Diseño metodológico	Cuantitativo, aplicado, correlacional causal, cuasi-experimental, transversal y de medidas repetidas.
Técnica e instrumento	Observación estructurada mediante experimentación computacional; registro de observación estructurada automatizado.
Herramientas de registro	Scripts en Python del repositorio del estudio (carpeta src/) (pandas, scikit-learn, shap, lime, SciPy) que exportan la ficha a CSV/Excel.
Unidad de análisis / observación	Alerta: conexión de red del conjunto de prueba a la que el Random Forest asigna una familia de malware.
Población y muestra	737 651 ventanas de tráfico (partición ARM, Kaggle) del dataset CIC-YNU-IoTMal 2026; muestra estratificada de n = 390 alertas (130 por familia: Mirai, DarkNexus y Gafgyt), con partición agrupada por binario.
Condiciones comparadas	C0 (pre-test): importancia global (MDI) del Random Forest, igual para todas las alertas. C1 (post-test): TreeSHAP. C2 (post-test): LIME.
Parámetros fijos	k = 5 características; R = 10 repeticiones; LIME con 5 000 muestras; perturbación $\varepsilon \sim N(0; 0{,}01 \cdot \sigma)$; valor de neutralización: mediana de cada característica en entrenamiento; semilla base = 42.

MATRIZ DEL REGISTRO DE OBSERVACIÓN ESTRUCTURADA (PRE-TEST VS. POST-TEST)

Instrucciones de llenado: Esta ficha se aplica individualmente a cada alerta observada. En la columna Pre-test se registra la métrica obtenida con la importancia global del Random Forest (sin explicación local). En las columnas Post-test se registran las métricas de las explicaciones locales que SHAP y LIME generan para la misma alerta. Los valores se obtuvieron con los scripts del experimento (src/04 y src/05); se muestra la alerta ALR-0005.

Código de alerta:	ALR-0005	**Familia real (estrato):**	DarkNexus
Etiqueta real:	DarkNexus	**Predicción RF / p(familia):**	DarkNexus / 0,501
Evaluador / Investigador:	Berrocal Barrientos Jorge Luis	**Semilla / fecha:**	42 / 2026

DIMENSIÓN / INDICADOR OBSERVADO	PRE-TEST (Importancia global RF)	POST-TEST (SHAP)	POST-TEST (LIME)	DIFERENCIA (Δ SHAP)	DIFERENCIA (Δ LIME)
DIMENSIÓN 1: FIDELIDAD DE LA EXPLICACIÓN					

DIMENSIÓN / INDICADOR OBSERVADO	PRE-TEST (Importancia global RF)	POST-TEST (SHAP)	POST-TEST (LIME)	DIFERENCIA (Δ SHAP)	DIFERENCIA (Δ LIME)
• Δp@k (k = 5): caída media de probabilidad	0,499	0,490	0,490	−0,008	−0,008
• TID@k (%): alertas cuya familia predicha cambia	1 (sí)	1 (sí)	1 (sí)	0	0
DIMENSIÓN 2: ESTABILIDAD DE LA EXPLICACIÓN					
• EE: Jaccard top-k entre R = 10 ejecuciones	1,000*	1,000	0,472	0,000	−0,528
• RP: Jaccard top-k ante perturbación ε	1,000*	0,667	0,429	−0,333	−0,571
DIMENSIÓN 3: PARSIMONIA DE LA EXPLICACIÓN					
• NC80: características para el 80 % de la atribución	9	8	10	−1	+1
• CT3 (%): atribución concentrada en el top-3	63,8	55,0	60,5	−8,8	−3,3

Nota. En la condición pre-test la explicación es la misma para todas las alertas; por ello sus valores de estabilidad (EE y RP) son constantes y se registran solo como referencia. Los valores corresponden a la alerta ALR-0005 (Figura 4 del artículo) y a los totales de la ejecución final (results/registro/registro_observacion.csv y results/tablas/contrastes.csv); los p-valores están ajustados por Holm. * Valor constante por definición.

REGISTRO GLOBAL DE LOS INDICADORES DEL MARCO (VARIABLE INDEPENDIENTE)

DIMENSIÓN / INDICADOR	SHAP	LIME	ÍNDICE ALCANZADO	OBSERVACIÓN
1. DESEMPEÑO DEL DETECTOR (común a ambos métodos)				
• F1 macro (%)	55,3	55,3	Macro (3 familias)	Exactitud 88,6 %; Mirai 95,5 %, DarkNexus 40,1 %, Gafgyt 30,3 %
• Tasa de falsos positivos, TFP (%)	16,2	16,2	Macro	Mirai 42,5 %: confunde familias minoritarias con Mirai
2. EFICIENCIA COMPUTACIONAL DE LA EXPLICACIÓN				
• Tiempo medio de explicación por alerta, TME (ms)	244	119 × 10	Mediana por alerta	LIME requiere R = 10 ejecuciones (≈ 1,2 s)
• Memoria pico, MP (MB)	n. d.	8,5	Pico en 20 alertas	tracemalloc no mide el núcleo C++ de TreeSHAP
3. CONCORDANCIA ENTRE MÉTODOS EXPLICATIVOS				
• Coincidencia top-k SHAP–LIME, CJ	0,25	0,25	Mediana (media 0,32)	Baja coincidencia del top-5; ambos priorizan Rate y Telnet
• Correlación de Spearman, $\bar{\rho}$	0,42	0,42	Mediana	Correlación moderada de los rankings

TOTALES CONSOLIDADOS DE LA MUESTRA (n = 390 alertas)

INDICADOR	PRE-TEST (mediana)	SHAP (mediana)	LIME (mediana)	p-valor	DECISIÓN SOBRE LA HIPÓTESIS
1. Fidelidad: Δp@k	0,024	0,031	0,033	C1: 1,00; C2: 0,152	H.E.1: no se acepta
1. Fidelidad: TID@k (%)	41,0	41,8	41,3	Q de Cochran: 0,174	H.E.1: no se acepta
2. Estabilidad: EE	1,000*	1,000	0,504	C2 > 0,80: 1,00	H.E.2: no se acepta
2. Estabilidad: RP	1,000*	0,667	0,429	C1, C2 > 0,80: 1,00	H.E.2: no se acepta
3. Parsimonia: NC80	9	7	12	C1: < 0,001; C2: 1,00	H.E.3: se acepta parcialmente (solo SHAP)
3. Parsimonia: CT3 (%)	63,8	66,7	48,5	C1: < 0,001; C2: 1,00	H.E.3: se acepta parcialmente (solo SHAP)

PROTOCOLO METODOLÓGICO

1. Preparación de los datos: descarga del tráfico de red (PCAP procesado, archivo pcap.csv) del dataset CIC-YNU-IoTMal 2026 desde Kaggle o desde la página oficial del CIC, y verificación de integridad (SHA-256). Se conservan las familias Mirai, DarkNexus y Gafgyt; se excluyen las ejecuciones benignas y las etiquetas Unknown, Generic y Other; se eliminan identificadores, columnas constantes o truncadas, valores infinitos o nulos y duplicados, y se aplica una partición 70/30 agrupada por el hash SHA-256 del binario para que ninguna muestra de malware aparezca en entrenamiento y prueba a la vez.

2. Entrenamiento del detector: Random Forest (scikit-learn) con hiperparámetros fijos y semilla reproducible; se registran F1 y TFP sobre el conjunto de prueba.

3. Fase Pre-test (línea de base): para cada alerta de la muestra se toma como explicación la importancia global (MDI) del Random Forest y se calculan Δp@k, TID@k, EE, RP, NC80 y CT3.

4. Aplicación del estímulo (tratamiento): integración del marco de explicabilidad: TreeSHAP y LIME generan, para cada alerta, la lista ordenada de características y sus contribuciones; se registran TME y MP.

5. Fase Post-test: cálculo de los mismos indicadores sobre las explicaciones SHAP y LIME de las mismas alertas, y de la concordancia entre ambos métodos (CJ y $\bar{\rho}$).

6. Análisis estadístico: prueba de Friedman y comparaciones post hoc de Wilcoxon con corrección de Holm ($\alpha = 0,05$) y Q de Cochran con McNemar exacto (TID@k) para H.E.1 y H.E.3; prueba de Wilcoxon de una muestra frente a 0,80 para H.E.2; tamaño del efecto r.

REFERENCIAS COMPLEMENTARIAS (definiciones conceptuales y diagnóstico)

Alahmadi, B. A., Axon, L., & Martinovic, I. (2022). 99% false positives: A qualitative study of SOC analysts' perspectives on security alarms. En *Proceedings of the 31st USENIX Security Symposium* (pp. 2783–2800). USENIX Association.

Barredo Arrieta, A., Díaz-Rodríguez, N., Del Ser, J., Bennetot, A., Tabik, S., Barbado, A., García, S., Gil-López, S., Molina, D., Benjamins, R., Chatila, R., & Herrera, F. (2020). Explainable artificial intelligence (XAI): Concepts, taxonomies, opportunities and challenges toward responsible AI. *Information Fusion, 58*, 82–115. https://doi.org/10.1016/j.inffus.2019.12.012

Lundberg, S. M., & Lee, S.-I. (2017). A unified approach to interpreting model predictions. En *Advances in Neural Information Processing Systems 30* (pp. 4765–4774). Curran Associates.

Lundberg, S. M., Erion, G., Chen, H., DeGrave, A., Prutkin, J. M., Nair, B., Katz, R., Himmelfarb, J., Bansal, N., & Lee, S.-I. (2020). From local explanations to global understanding with explainable AI for trees. *Nature Machine Intelligence, 2*(1), 56–67. https://doi.org/10.1038/s42256-019-0138-9

Miller, T. (2019). Explanation in artificial intelligence: Insights from the social sciences. *Artificial Intelligence, 267,* 1–38. https://doi.org/10.1016/j.artint.2018.07.007

Ribeiro, M. T., Singh, S., & Guestrin, C. (2016). "Why should I trust you?": Explaining the predictions of any classifier. En *Proceedings of the 22nd ACM SIGKDD International Conference on Knowledge Discovery and Data Mining* (pp. 1135–1144). ACM. https://doi.org/10.1145/2939672.2939778

Vectra AI. (2023). *2023 State of Threat Detection* [Informe de investigación]. https://content.vectra.ai/hubfs/downloadable-assets/V_2023-State-of-Threat-Detection.pdf